

Deteksi Anomali Menggunakan Isolation Forest, Local Outlier Factor (LOF), dan DBSCAN Pada Studi Kasus Indeks Standar Pencemaran Udara (ISPU) DKI Jakarta 2010–2021

ARTICLE INFO

Keywords:

Anomaly Detection,
Isolation Forest, Local
Outlier Factor, DBSCAN,
Consensus Voting,
kualitas udara, ISPU
Jakarta, preprocessing,
data leakage

*N. R. Mujahidin., W. S.
Luthfia, F. A. Safitri, A.
Salsabila, J. F. Br.
Perangin-Angin, T. H.
NST, T. H. Diraputra,*

“Deteksi Anomali
Menggunakan Isolation
Forest, LOF, dan
DBSCAN: Studi Kasus
ISPU DKI Jakarta
2010-2021” *Jurnal Ilmiah
Teknologi 2026*

ABSTRACT

Deteksi anomali merupakan tahap penting dalam preprocessing data untuk mengidentifikasi observasi yang menyimpang secara signifikan dari pola umum dataset. Penelitian ini mengevaluasi tiga metode deteksi anomali Isolation Forest, Local Outlier Factor (LOF), dan DBSCAN pada dataset Indeks Standar Pencemaran Udara (ISPU) DKI Jakarta tahun 2010–2021 (5.533 rekaman dari 5 stasiun pemantauan). Pipeline bebas data leakage diterapkan: train-test split (80:20, stratified) dilakukan terlebih dahulu sebelum seluruh proses preprocessing dan deteksi anomali. Parameter contamination diestimasi via aturan 3-sigma; parameter eps DBSCAN ditentukan melalui k-distance plot pada data yang direduksi PCA 2 komponen. Consensus voting (threshold $\geq 2/3$ metode) digunakan untuk mengidentifikasi anomali yang robust. Evaluasi dilakukan dengan membandingkan performa Random Forest sebelum dan sesudah pembersihan anomali menggunakan Accuracy, Precision, Recall, F1-Score, dan AUC-ROC. Kualitas udara dikategorikan menjadi dua kelas: Normal (BAIK/SEDANG) dan Tidak Sehat (TIDAK SEHAT/SANGAT TIDAK SEHAT/BERBAHAYA). Hasil menunjukkan bahwa ketiga metode menangkap aspek anomali polutan udara yang berbeda; consensus voting menghasilkan deteksi yang lebih konservatif dan mengurangi false positive.

1. Pendahuluan

1.1 Latar Belakang

Dalam era digitalisasi global, kualitas data menjadi faktor kritis dalam keberhasilan proses *Knowledge Discovery in Databases* (KDD). Tahap *preprocessing*, yang mencakup pembersihan, transformasi, dan reduksi data menghabiskan sekitar 60–80% dari keseluruhan waktu dalam proyek *data mining* [1]. Salah satu tantangan utama dalam tahap ini adalah keberadaan anomali, yaitu observasi yang menyimpang secara signifikan dari pola umum dataset. Apabila tidak ditangani, anomali dapat mengganggu proses pembelajaran model, menyebabkan estimasi parameter yang bias, serta menurunkan kemampuan generalisasi model pada data baru [2].

Kualitas udara merupakan salah satu indikator penting dalam menilai kondisi lingkungan dan kesehatan masyarakat, khususnya di wilayah perkotaan padat seperti DKI Jakarta. Indeks Standar Pencemaran Udara (ISPU) digunakan oleh Dinas Lingkungan Hidup DKI Jakarta untuk mengukur tingkat kualitas udara harian berdasarkan konsentrasi polutan utama, yaitu PM10, SO₂, CO, O₃, dan NO₂. Data ISPU yang dikumpulkan secara harian dari lima stasiun pemantauan seringkali mengandung nilai ekstrem atau tidak biasa, yang dapat bersumber dari faktor lingkungan, kesalahan pembacaan sensor, maupun kejadian cuaca yang tidak lazim.

Berbagai metode deteksi anomali telah dikembangkan dengan pendekatan yang berbeda. Isolation Forest bekerja berdasarkan prinsip isolasi berbasis pohon acak dan unggul untuk anomali global berdimensi tinggi [3]. *Local Outlier Factor* (LOF) mengukur keanehan suatu titik relatif terhadap kepadatan lokalnya sehingga mampu mendeteksi anomali kontekstual [4]. DBSCAN mengidentifikasi anomali sebagai titik-titik yang tidak masuk dalam cluster densitas manapun [5]. Masing-masing metode memiliki keunggulan dan keterbatasan yang berbeda, oleh karena itu, diperlukan suatu pendekatan ensemble untuk meningkatkan robustness hasil deteksi dan meminimalkan *false positive* individual.

Penelitian ini mengimplementasikan dan membandingkan ketiga metode tersebut pada dataset ISPU DKI Jakarta periode 2010–2021, kemudian menggabungkan hasilnya melalui *consensus voting*. Dampak dari proses pembersihan anomali kemudian dievaluasi secara objektif melalui perbandingan performa model klasifikasi Random Forest pada training set sebelum dan sesudah pembersihan, dengan test set yang identik dan tidak dimodifikasi. Diharapkan penelitian ini memberikan kontribusi metodologis dalam penerapan teknik deteksi anomali yang bebas *data leakage* pada data lingkungan hidup.

1.2 Rumusan Masalah

Berdasarkan latar belakang, maka rumusan masalah dalam penelitian ini adalah

1. Bagaimana perbandingan efektivitas metode Isolation Forest, LOF, dan DBSCAN dalam mendeteksi anomali pada dataset ISPU DKI Jakarta berdasarkan jumlah dan karakteristik anomali yang teridentifikasi?
2. Metode mana yang paling konsisten dalam mendeteksi anomali sehingga terpilih melalui pendekatan consensus voting (≥ 2 dari 3 metode)?
3. Bagaimana pengaruh penghapusan anomali terhadap performa model klasifikasi kualitas udara dibandingkan dengan kondisi baseline tanpa penghapusan?

1.3 Tujuan Masalah

Tujuan dari penelitian ini adalah:

1. Mengimplementasikan dan membandingkan tiga metode deteksi anomali (Isolation

- Forest, LOF, dan DBSCAN) pada dataset ISPU DKI Jakarta, serta menganalisis perbedaan karakteristik anomali yang teridentifikasi oleh masing-masing metode.
2. Mengidentifikasi anomali yang terdeteksi secara konsisten oleh minimal dua dari tiga metode menggunakan pendekatan *consensus voting*, guna meningkatkan kepercayaan hasil deteksi.
 3. Mengevaluasi dampak penghapusan anomali konsensus terhadap performa model klasifikasi kualitas udara berdasarkan metrik Accuracy, Precision (macro), Recall (macro), F1-Score (macro), dan AUC-ROC.

1.4 Batasan Masalah

Batasan masalah dari laporannya adalah sebagai berikut:

1. Dataset yang digunakan adalah data ISPU DKI Jakarta periode Januari 2010 – Februari 2025 yang diperoleh dari platform Kaggle bersumber dari Dinas Lingkungan Hidup DKI Jakarta, dengan total 5.533 baris setelah pembersihan awal.
2. Fitur yang digunakan terbatas pada lima konsentrasi polutan numerik yaitu, PM10, SO₂, CO, O₃, dan NO₂. Kolom PM2.5 dikecualikan karena proporsi *missing value*-nya melebihi 72%.
3. Deteksi anomali hanya dilakukan pada data training (80% dari total data) untuk menghindari *data leakage*, data test yang tidak disentuh hingga tahap evaluasi akhir.
4. Algoritma klasifikasi yang digunakan sebagai evaluator dampak adalah *Random Forest Classifier* dengan parameter *n_estimators*=100 dan *random_state*=42.
5. Evaluasi dilakukan menggunakan metrik: *Accuracy*, *Precision (macro)*, *Recall (macro)*, *F1-Score (macro)*, dan AUC-ROC. *F1-Score (macro)* ditetapkan sebagai metrik utama.
6. Perbandingan hanya dilakukan antara dua kondisi yaitu, *baseline* merupakan penghapusan anomali dan *cleaned* yaitu setelah penghapusan anomali konsensus. Metode imputation atau resampling tidak termasuk dalam lingkup penelitian ini.

2. Tinjauan Pustaka

2.1. Data mining dan Preprocessing

Data mining adalah ekstraksi pengetahuan yang bermanfaat dari data besar melalui statistik dan komputasional [1]. Dalam kerangka *Knowledge Discovery in Database* (KDD), tahap *preprocessing* yang mencakup pembersihan, integrasi, transformasi, dan reduksi dimensi adalah fondasi krusial bagi kualitas analisis [1]. Mengingat perannya dalam menjamin konsistensi data sebelum data diolah oleh algoritma, tahap ini menghabiskan sekitar 60–80% total waktu proyek [1].

Masalah utama dalam *preprocessing* ini adalah keberadaan anomali atau *outlier* yang menyimpang signifikan dari distribusi dataset [2]. Jika tidak ditangani, anomali dapat membiaskan estimasi parameter model, meningkatkan variansi prediksi, serta menurunkan kemampuan generalisasi [2]. Pada data kualitas udara hasil pemantauan melalui sensor, anomali ini umumnya dipicu oleh malfungsi perangkat, fenomena lingkungan ekstrem, atau kesalahan pencatatan [2].

2.2 Anomaly Detection

Anomali dalam konteks data mining didefinisikan sebagai pola atau titik data yang tidak sesuai dengan perilaku yang diharapkan dalam suatu dataset, dan berbeda dengan *outlier* yang umumnya merujuk pada nilai ekstrem satu variabel tunggal, anomali bersifat lebih kompleks karena dapat melibatkan kombinasi fitur yang secara bersamaan membentuk pola tidak biasa [2]. Berdasarkan klasifikasinya, anomali dibagi menjadi tiga jenis [2]: (1) *Point anomaly*, yaitu titik data individual yang menyimpang signifikan dari distribusi umum; (2) *Contextual anomaly*, yaitu data yang anomali hanya dalam konteks tertentu namun normal di konteks lain; dan (3) *Collective anomaly*, yaitu kumpulan titik data yang secara individual normal tetapi secara kolektif membentuk pola yang tidak biasa. Ketiga jenis anomali tersebut berpotensi hadir secara bersamaan dalam dataset ISPU DKI Jakarta [2].

Keberadaan anomali yang tidak ditangani dapat memberikan dampak serius terhadap performa model klasifikasi, di antaranya mendistorsi estimasi parameter model, menambah *noise* pada *decision boundary*, serta menurunkan kemampuan generalisasi terhadap data baru [2]. Dalam kerangka *Knowledge Discovery in Databases* (KDD), deteksi anomali menjadi tahap krusial sebelum pelatihan model [1] khususnya pada data ISPU yang dikumpulkan melalui sensor pemantauan, di mana anomali yang bersumber dari malfungsi perangkat atau kejadian cuaca ekstrem berpotensi menyebabkan model salah mempelajari pola kondisi kualitas udara [1][2].

2.3 Metode Deteksi Anomali

Tabel 1. Metode deteksi anomali

Metode	Pendekatan	Prinsip Kerja	Parameter Kunci	Kelebihan/Kekurangan
<i>Isolation Forest</i>	<i>Tree based</i>	Mengisolasi anomali dengan <i>random splits</i> anomali memerlukan lebih sedikit <i>split</i> untuk terisolasi karena jauh dari kluster	contamination: estimasi proporsi anomali; n_estimators: jumlah tree	+Efisien pada data berdimensi tinggi -Kurang efektif untuk anomali yang membentuk kluster

		data normal		
LOF	<i>Density based</i>	Membandingkan <i>local density</i> suatu titik terhadap <i>neighbor</i> -nya, anomali memiliki <i>density</i> yang jauh lebih rendah dari <i>neighbor</i>	n_neighbors: jumlah neighbor untuk estimasi density; contamination	+Mampu mendeteksi anomali lokal -Lambat pada dataset besar, sensitif terhadap pemilihan nilai k
DBSCAN	<i>Clustering</i>	Membentuk kluster berdasarkan <i>density</i> titik yang tidak masuk kluster mana pun (<i>noise</i>) dianggap anomali	eps: radius neighborhood (dari k-distance plot); min_samples: minimum titik untuk core point	+Tidak perlu menentukan jumlah kluster, mampu mendeteksi kluster -Sensitif terhadap pemilihan eps-Wajib menggunakan k-distance plot

2.3.1 Isolation Forest

Isolation Forest bekerja berdasarkan prinsip bahwa anomali, karena sifatnya yang jarang dan berbeda, lebih mudah diisolasi melalui random partitioning dibandingkan data normal [3]. Setiap instance pohon membagi data secara rekursif pada fitur dan threshold acak; sampel anomali rata-rata memerlukan path length yang lebih pendek untuk terisolasi [3]. Anomaly score dihitung berdasarkan rata-rata path length terhadap expected path length semakin pendek jalurnya, semakin tinggi probabilitas titik tersebut diklasifikasikan sebagai anomali [3].

2.3.2 Local Outlier Factor (LOF)

LOF mengukur tingkat isolasi suatu titik berdasarkan perbandingan *local reachability density* titik tersebut terhadap *neighbor*-nya [4]. *LOF score* ≈ 1 berarti densitas titik sebanding dengan *neighbor*-nya, mengindikasikan data normal [4]. Sebaliknya, *LOF* $\gg 1$ menandakan titik berada di area yang jauh lebih *sparse* dibandingkan sekitarnya indikasi kuat bahwa titik tersebut merupakan anomali lokal [4].

2.3.3 DBSCAN

DBSCAN membentuk kluster berdasarkan kepadatan data dalam radius eps [5]. Sebuah titik disebut *core point* jika memiliki setidaknya min_samples titik dalam radius eps-nya; titik yang tidak memenuhi syarat tersebut dan tidak terjangkau oleh *core point* mana pun ditetapkan sebagai *noise* dan dianggap anomali [5]. Berbeda dengan Isolation Forest dan LOF, DBSCAN tidak menghasilkan skor numerik status anomali ditentukan murni melalui keanggotaan kluster [5]. Metode ini sangat sensitif terhadap pemilihan nilai eps, sehingga penggunaan *k-distance plot* untuk menentukan nilai eps secara empiris sangat dianjurkan [5].

2.4 Consensus Voting

Consensus voting merupakan metode ensemble untuk menggabungkan hasil deteksi dari beberapa algoritma anomaly detection agar hasil lebih stabil dan mengurangi false positive [14][23]. Pada penelitian ini digunakan Isolation Forest, LOF, dan DBSCAN yang memiliki karakteristik deteksi berbeda [3][4][5]. Mekanisme voting menggunakan majority voting, yaitu data dikategorikan sebagai anomali jika terdeteksi oleh minimal dua dari tiga metode.

2.5 Metrik Evaluasi

Evaluasi performa model deteksi anomali dilakukan menggunakan beberapa metrik seperti accuracy, precision, recall, F1-score, AUC-ROC, dan confusion matrix. Penggunaan beberapa metrik diperlukan karena satu metrik saja belum cukup menggambarkan performa model, terutama pada dataset tidak seimbang [19]. Accuracy mengukur proporsi prediksi benar terhadap seluruh data [11], dengan rumus:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

TP adalah data positif yang terdeteksi benar, TN data negatif yang terdeteksi benar, FP data normal yang salah diklasifikasikan sebagai anomali, dan FN data anomali yang tidak terdeteksi. Namun, accuracy kurang efektif pada dataset tidak seimbang. Precision mengukur ketepatan prediksi positif model, dengan rumus:

$$Precision = \frac{TP}{TP + FP}$$

Precision menunjukkan proporsi prediksi anomali yang benar-benar merupakan anomali. Metrik ini penting ketika kesalahan *false positive* perlu diminimalkan[[16]]. Recall mengukur kemampuan model dalam mendeteksi seluruh data positif[16], dengan rumus:

$$Recall = \frac{TP}{TP + FN}$$

F1-score merupakan rata-rata harmonik dari precision dan recall, yang digunakan untuk menyeimbangkan kedua metrik[12], dengan rumus:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$


F1-score digunakan pada dataset tidak seimbang karena mempertimbangkan false positive dan false negative. AUC-ROC mengukur kemampuan model membedakan kelas positif dan negatif. Semakin mendekati nilai 1, semakin baik performa model. Confusion matrix merupakan tabel yang berisi nilai TP, TN, FP, dan FN untuk membantu analisis hasil klasifikasi model [12][16].

2.6 Penelitian Terkait

Fachmi et al. (2026) melakukan klasifikasi ISPU DKI Jakarta menggunakan *Random Forest* + SMOTE pada data Januari–Agustus 2025. Hasilnya mencapai akurasi 99,50% dengan PM2.5 sebagai fitur paling dominan 30,68%. Penelitian ini berbeda dalam paradigma *unsupervised* vs *supervised*, rentang dataset 11 tahun vs 8 bulan, dan kontribusi metodologis *ensemble anomaly detection* vs *single classifier*. Rahmadenti (2025) menggunakan *K-Means Clustering* untuk memetakan pola kualitas udara Jakarta, namun bersifat deskriptif tanpa model prediktif. Penelitian ini berkontribusi dengan pipeline anomaly detection + evaluasi dampak yang tidak diteliti keduanya.

3. Metodologi

3.1 Alur Penelitian



Gambar 1. Alur penelitian

3.2 Deskripsi Dataset

Dataset yang digunakan adalah ISPU DKI Jakarta dari Dinas Lingkungan Hidup DKI Jakarta melalui Kaggle. Dataset berisi data harian lima stasiun pemantau periode 2010–2021 sebanyak 5.533 data setelah pembersihan awal. Kolom PM2.5 dihapus karena memiliki missing value tinggi. Target dibagi menjadi dua kelas, yaitu Normal (BAIK dan SEDANG) serta Tidak Sehat. Dataset terdiri dari 3.502 data Normal dan 2.031 data Tidak Sehat dengan imbalance ratio 1,72. Fitur yang digunakan meliputi PM10, SO₂, CO, O₃, dan NO₂.

Tabel 2. Deskripsi Seluruh Kolom Dataset ISPU DKI Jakarta

No	Nama Kolom	Tipe	Deskripsi	Missing(%)	Digunakan
1	tanggal	Teks	Tanggal pengukuran (YYYY-MM-DD)	0%	Tidak (EDA)
2	stasiun	Kategori kal	Nama stasiun pemantau DKI1-DKI5	0,02%	imputasi kelompok
3	pm25	Numerik	Konsentrasi partikel PM2.5 (µg/m ³)	72,63%	Dikecualikan

4	pm10	Numerik	Konsentrasi partikel PM10 ($\mu\text{g}/\text{m}^3$)	5,62%	Fitur utama
5	so2	Numerik	Konsentrasi SO_2 ($\mu\text{g}/\text{m}^3$)	2,28%	Fitur utama
6	co	Numerik	Konsentrasi CO ($\mu\text{g}/\text{m}^3$)	1,52%	Fitur utama
7	o3	Numerik	Konsentrasi O_3 ($\mu\text{g}/\text{m}^3$)	1,81%	Fitur utama
8	no2	Numerik	Konsentrasi NO_2 ($\mu\text{g}/\text{m}^3$)	1,84%	Fitur utama
9	max	Numerik	Nilai ISPU tertinggi hari itu	0,02%	Tidak (redundan)
10	critical	Kategori kal	Polutan dengan nilai ISPU tertinggi	0,07%	Tidak
11	categori	Kategori kal	Kategori kualitas udara: (BAIK - BERBAHAYA)	0%	Basis konstruksi variabel target

3.3 Prosedur Eksperimen

3.3.1 Preprocessing Data

Data dibagi menjadi training set (80%) dan test set (20%) menggunakan stratified sampling. menghasilkan 4.426 sampel training dan 1.107 sampel test.. StandardScaler di fit hanya pada training set, lalu ditransformasikan ke test set tanpa re-fit [14].

Python

```
# 1. Imputasi median per stasiun
```

```
df_clean = df.copy()
```

```
for col in FEATURE_COLS:
```

```
    df_clean[col] = df_clean.groupby('stasiun')[col].transform(
```

```
        lambda x: x.fillna(x.median())
```

```
)
```

```
# Fallback: jika masih ada NaN (stasiun hanya punya NaN), isi dengan median global
```

```
df_clean[col] = df_clean[col].fillna(df_clean[col].median())
```

```
print("Missing values setelah imputasi:")
```

```
print(df_clean[FEATURE_COLS].isnull().sum())
```

```
# 2. Siapkan X dan y
```

```
X_all = df_clean[FEATURE_COLS].values
```

```
y_all = df_clean['target'].values

print(f"\nUkuran dataset final: {X_all.shape[0]:,} sampel x {X_all.shape[1]} fitur")

print(f"Distribusi kelas: Normal={y_all.sum()==0} → 0={int((y_all==0).sum())},  
1={int((y_all==1).sum())}")

# 3. Train-Test Split (SEBELUM scaling - mencegah data leakage)

X_train_raw, X_test_raw, y_train_np, y_test_np = train_test_split(
    X_all, y_all, test_size=0.2, random_state=RANDOM_STATE, stratify=y_all
)

print(f"\nTrain-Test Split (80:20, stratified):")

print(f" Training set : {X_train_raw.shape[0]:,} sampel | target 1: {y_train_np.sum()}")

print(f" Test set      : {X_test_raw.shape[0]:,} sampel | target 1: {y_test_np.sum()}")

# 4. Standarisasi (fit HANYA pada train)

scaler = StandardScaler()

X_train_np = scaler.fit_transform(X_train_raw)

X_test_np = scaler.transform(X_test_raw)
```

3.3.2 Metode Deteksi Anomali yang Digunakan

Nilai contamination untuk Isolation Forest dan LOF ditentukan menggunakan aturan 3 sigma, sehingga diperoleh contamination sebesar 0,0556.

1. Isolation Forest mendeteksi anomali berdasarkan kemudahan titik untuk diisolasi dari data lain [3]. Parameter yang digunakan yaitu $n_estimators=100$, $contamination=0,0556$, dan $random_state=42$ [6].
2. LOF mengukur tingkat keanehan titik berdasarkan kepadatan lokal tetangganya [4]. Parameter yang digunakan yaitu $n_neighbors=20$ dan $contamination=0,0556$.
3. DBSCAN mendeteksi anomali sebagai titik yang tidak masuk ke dalam cluster [23]. Metode ini dijalankan pada hasil PCA 2 komponen dengan parameter $eps=7,621$ dan $min_samples=5$.

3.3.3 Algoritma Klasifikasi

Algoritma klasifikasi yang digunakan adalah Random Forest Classifier dengan parameter $n_estimators=100$ dan $random_state=42$ [11]. Model dilatih pada data baseline dan data setelah penghapusan anomali. Evaluasi dilakukan menggunakan test set yang sama pada kedua kondisi.

3.3.4 Metrik Evaluasi

Metrik evaluasi yang digunakan meliputi: *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan AUC-ROC. *F1-Score* ditetapkan sebagai metrik utama karena lebih representatif untuk data dengan distribusi kelas tidak sepenuhnya seimbang dibandingkan accuracy semata [12].

4. Hasil dan Pembahasan


4.1 Eksplorasi Data (EDA)


Dataset ISPU DKI Jakarta terdiri dari 5.533 rekaman harian dari 5 stasiun pemantau (DKI1–DKI5) periode Januari 2010 – Februari 2025, dengan 5 fitur polutan numerik: PM10, SO₂, CO, O₃, dan NO₂. Tabel 1 merangkum statistik deskriptif utama.

Tabel 3. Statistik deskriptif fitur polutan (μg/m³)

Polutan	Mean	Std	Min	Median	Max	Missing (%)
PM10	56,41	20,01	2	57	187	5,62%
SO ₂	22,43	15,45	0	18	112	2,28%
CO	20,42	11,96	0	18	119	1,52%
O ₃	77,47	51,80	4	69	314	1,81%
NO ₂	14,34	10,04	1	12	202	1,84%

Distribusi target biner menunjukkan 3.502 rekaman Normal (63,29%) dan 2.031 rekaman Tidak Sehat (36,71%) dengan *imbalance ratio* 1,72:1 relatif seimbang dibandingkan dataset klasifikasi pada umumnya. Analisis per stasiun mengungkap bahwa DKI2 (Kelapa Gading) dan DKI5 (Kebon Jeruk) memiliki proporsi "Tidak Sehat" tertinggi (~49%), sedangkan DKI1 (Bunderan HI) paling rendah (5,5%). Secara temporal, puncak polusi terjadi pada 2013–2014 dan 2018–2019. Korelasi antarpolutan bersifat lemah hingga sedang, mengindikasikan bahwa setiap polutan membawa informasi yang berbeda; hal ini memperkuat relevansi pendekatan deteksi anomali multidimensi.






4.2 Preprocessing dan Train-Test Split

Nilai hilang pada setiap fitur diimputasi menggunakan median per stasiun untuk menghormati variasi spasial antarpemantau, dengan *fallback* median global apabila suatu stasiun hanya memiliki nilai hilang. Pembagian data dilakukan *sebelum* preprocessing apapun guna mencegah *data leakage* [1]: 80% data (4.426 sampel) digunakan sebagai *training set* dan 20% (1.107 sampel) sebagai *test set* dengan stratifikasi kelas. StandardScaler di-*fit* eksklusif pada *training set*, kemudian ditransformasikan ke *test set* tanpa re-*fit* [14].

4.3 Estimasi Parameter Deteksi Anomali

Nilai *contamination* untuk Isolation Forest dan LOF ditetapkan melalui aturan 3-sigma pada data training, menghasilkan proporsi outlier 5,5581% yang dibulatkan menjadi $\text{contamination} = 0,0556$. Parameter eps DBSCAN ditentukan melalui *k-distance plot* ($k=5$) pada ruang PCA 2 komponen. Deteksi *knee point* otomatis menghasilkan $\text{eps} = 7,621$, sebagaimana ditunjukkan pada Gambar 4.



4.4 Deteksi Anomali dan Consensus Voting


Ketiga metode dijalankan pada *training set* (4.426 sampel). Ringkasan hasil deteksi

disajikan pada Tabel 2, sedangkan visualisasi distribusi anomali dalam ruang PCA 2D ditampilkan pada Gambar 5.


Tabel 4. Ringkasan deteksi anomali per metode pada training test

Metode	Anomali Terdeteksi	Persentasi (%)	Parameter Kunci
Isolation Forest	247	5,581%	contamination=0,0556, n_estimators=100
LOF	247	5,581%	n_neighbors=20, contamination=0,0556
DBSCAN	0	0,000%	eps=7,621 (PCA-2), min_samples=5

Consensus voting dengan threshold ≥ 2 dari 3 metode menghasilkan distribusi: 4.030 sampel tidak terdeteksi oleh metode manapun, 298 sampel terdeteksi hanya oleh 1 metode, dan 98 sampel terdeteksi oleh tepat 2 metode. Tidak ada sampel yang disepakati ketiga metode sekaligus. Total anomali konsensus yang dihapus dari training set berjumlah **98 rekaman (2,21%)**, sebagaimana tervisualisasi pada Gambar 5.



Gambar 5. Sebaran anomali per metode dalam ruang PCA 2D



Gambar 6. Distribusi consensus voting dan anomali konsensus



4.5 Evaluasi Dampak Cleaning terhadap Klasifikasi

Model Random Forest dilatih pada dua kondisi: *baseline* (4.426 sampel) dan *cleaned*

(4.328 sampel setelah penghapusan 98 anomali konsensus). Keduanya dievaluasi pada *test set* yang identik (1.107 sampel). Tabel 3 dan Gambar 7-8 menyajikan perbandingan performa secara lengkap.

Tabel 5. Perbandingan performa klasifikasi Baseline vs Setelah cleaning

Konfigurasi	Accuracy	Precision (macro)	Recall (macro)	F-1 Score (macro)	AUC-ROC
Baseline (Tanpa Cleaning)	0,9566	0,9556	0,9507	0,9531	0,9921
Cleaning (Consensus $\geq 2/3$)	0,9548	0,9547	0,9478	0,9510	0,9919
Delta (Cleaning - Baseline)	-0,0018	-0,0009	-0,0029	-0,0021	-0,0002



4.6 Pembahasan

4.6.1 Karakteristik Deteksi Tiap Mode

Isolation Forest dan LOF masing-masing mendeteksi 247 anomali (5,58%), namun dengan perspektif berbeda: IF berbasis isolasi pohon acak menangkap *global anomaly* rekaman hari-hari dengan konsentrasi PM10 atau CO yang secara holistik jauh dari distribusi utama, seperti yang lazim terjadi saat kebakaran lahan atau inversi suhu. LOF berbasis kepadatan lokal mendeteksi *local anomaly* kombinasi polutan yang tidak lazim meski tidak selalu ekstrem secara global. DBSCAN mendeteksi 0 anomali karena distribusi data ISPU dalam ruang PCA 2D bersifat kontinu tanpa *density gap* yang cukup untuk membentuk lebih dari satu cluster; ini merupakan temuan valid yang mencerminkan sifat data kualitas udara, bukan kegagalan implementasi.

4.6.2 Efektivitas Consensus Voting

Karena DBSCAN tidak berkontribusi, consensus voting secara operasional berfungsi sebagai interseksi $IF \cap LOF$, menghasilkan 98 rekaman (2,21%) yang dikonfirmasi oleh dua perspektif berbeda secara sekaligus. Pendekatan ini menghasilkan deteksi yang lebih konservatif dan berpotensi mereduksi *false positive* dibandingkan metode tunggal. Anomali konsensus berpotensi merepresentasikan kejadian nyata seperti episode pencemaran ekstrem akibat kebakaran hutan atau kondisi meteorologi khusus, bukan sekadar *noise* pengukuran sensor.

4.6.3 Dampak Cleaning terhadap Klasifikasi Kualitas Udara

Penghapusan 98 anomali konsensus dari *training set* menurunkan seluruh metrik secara kecil namun konsisten, dengan penurunan terbesar pada Recall (-0,0029). Penurunan ini mengindikasikan bahwa sebagian rekaman yang dihapus merupakan contoh kelas "Tidak Sehat" yang informatif kondisi polutan ekstrem yang justru penting dikenali model. Namun demikian, model *baseline* tetap mempertahankan performa sangat tinggi ($F1 = 0,9531$; $AUC-ROC = 0,9921$), sehingga dampak *cleaning* bersifat terukur dan tidak merusak kemampuan generalisasi. Hal ini menunjukkan bahwa Random Forest cukup *robust* terhadap keberadaan sejumlah kecil anomali dalam *training set* untuk dataset dengan karakteristik seperti ISPU Jakarta.

5. Kesimpulan dan Saran

5.1 Kesimpulan

Berdasarkan eksperimen deteksi anomali pada dataset ISPU DKI Jakarta 2010–2021, diperoleh tiga kesimpulan yang menjawab rumusan masalah penelitian ini.

Pertama, mengenai perbandingan efektivitas metode: Isolation Forest dan LOF masing-masing mendeteksi 247 anomali (5,58%) dari 4.426 sampel *training*, sementara DBSCAN mendeteksi 0 anomali akibat distribusi data ISPU yang bersifat kontinu tanpa *density gap* dalam ruang PCA 2D. IF efektif menangkap *global anomaly* berbasis isolasi pohon, sedangkan LOF unggul dalam mendeteksi *local anomaly* berbasis kerapatan ketetanggaan; keduanya saling melengkapi.

Kedua, mengenai efektivitas consensus voting: Dengan threshold ≥ 2 dari 3 metode, diperoleh 98 anomali konsensus (2,21%) yang secara operasional merupakan interseksi $IF \cap LOF$. Pendekatan ini menghasilkan deteksi yang lebih konservatif dan berpotensi mereduksi *false positive* dibandingkan deteksi metode tunggal, meski perbandingan empiris langsung terhadap metode tunggal belum dilakukan dalam penelitian ini.

Ketiga, mengenai dampak terhadap klasifikasi: Penghapusan anomali konsensus menurunkan F1-Score sebesar 0,0021 (−0,22%) dan AUC-ROC sebesar 0,0002 (−0,02%). Penurunan terbesar terjadi pada Recall (−0,0029), mengindikasikan hilangnya beberapa contoh kondisi "Tidak Sehat" yang informatif. Secara keseluruhan, dampak *cleaning* bersifat terukur dan tidak signifikan, membuktikan bahwa Random Forest cukup *robust* terhadap sejumlah kecil anomali dalam data ISPU.

5.2 Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan utama: (1) PM2.5 dikecualikan karena >72% *missing value*, padahal merupakan indikator kualitas udara paling relevan secara kesehatan; (2) evaluasi hanya menggunakan *single random split* bukan *time-aware split* sehingga estimasi performa tidak mencerminkan kemampuan generalisasi ke data masa depan; (3) konteks temporal dan meteorologi (bulan, musim, suhu) tidak digunakan sebagai fitur; serta (4) DBSCAN memerlukan tuning parameter yang lebih eksploratif untuk data dengan distribusi kontinu.

5.3 Saran

Penelitian lanjutan disarankan untuk: (1) mengadopsi *TimeSeriesSplit* sebagai protokol evaluasi utama agar urutan temporal dihormati; (2) mengintegrasikan fitur meteorologi dan temporal untuk meningkatkan kontekstualisasi deteksi anomali; (3) mengeksplorasi HDBSCAN sebagai alternatif DBSCAN yang lebih adaptif terhadap variasi kepadatan lokal; serta (4) memvalidasi anomali yang terdeteksi terhadap catatan kejadian nyata (kebakaran hutan, data BMKG) untuk mengonfirmasi korespondensi dengan peristiwa pencemaran terdokumentasi.

References

- [1] M. Kember, M. K. Han, dan J. Pei, "Data Mining: Concepts and Techniques," 3rd ed. Amsterdam: Elsevier, 2012.
- [2] V. Chandola, A. Banerjee, dan V. Kumar, "Anomaly detection: A survey," *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009.
- [3] F. T. Liu, K. M. Ting, dan Z. H. Zhou, "Isolation forest," in *ICDM 2008*, IEEE, pp. 413–422, 2008.
- [4] M. M. Breunig, H. P. Kriegel, R. T. Ng, dan J. Sander, "LOF: Identifying density-based local outliers," in *SIGMOD 2000*, pp. 93–104, 2000.
- [5] M. Ester, H. P. Kriegel, J. Sander, dan X. Xu, "A density-based algorithm for discovering clusters," in *KDD 1996*, pp. 226–231, 1996.
- [6] H. Xu, G. Pang, Y. Wang, dan Y. Wang, "Deep Isolation Forest for Anomaly Detection," *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 12, pp. 12228–12241, 2023.
- [7] M. Heigl et al., "On the Improvement of the Isolation Forest Algorithm for Outlier Detection with Streaming Data," *Electronics*, vol. 10, no. 13, p. 1534, 2021.
- [8] R. C. Ripan et al., "An Isolation Forest Learning Based Outlier Detection Approach for Effectively Classifying Cyber Anomalies," *arXiv preprint arXiv:2101.03141*, 2020.
- [9] D. Cortes, "Isolation forests: looking beyond tree depth," *arXiv preprint arXiv:2111.11639*, 2021.
- [10] L. Zhang, Y. Zhu, J. Ren, W. Lu, dan Y. Yao, "A method for detecting abnormal behavior of ships based on multi-dimensional density distance and an abnormal isolation mechanism," *Mathematical Biosciences and Engineering*, vol. 20, no. 6, pp. 10941–10959, 2023.
- [11] Ž. Đ. Vujović, "Classification model evaluation metrics," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 12, no. 6, pp. 599–607, 2021.
- [12] D. J. Hand, P. Christen, dan N. Kirielle, "F*: an interpretable transformation of the F-measure," *Machine Learning*, vol. 110, pp. 451–456, 2021.
- [13] J. Yuan et al., "A survey of visual analytics techniques for machine learning," *Computational Visual Media*, vol. 7, no. 1, pp. 3–36, 2021.
- [14] A. S. Kumar, A. K. Behera, S. Dehuri, dan A. Ghosh, "An outliers detection and elimination framework in classification task of data mining," *Decision Analytics Journal*, vol. 6, 100164, 2023.
- [15] Y. Gong et al., "A survey on dataset quality in machine learning," *Information and Software Technology*, vol. 162, 107268, 2023.
- [16] R. Yacouby dan D. Axman, "Probabilistic extension of precision, recall, and F1 score for more thorough evaluation of classification models," in *Proc. Eval4NLP Workshop*, pp. 79–91, 2020.
- [17] S. Sathyanarayanan dan B. R. Tantri, "Confusion matrix-based performance evaluation metrics," *African Journal of Biomedical Research*, vol. 27, no. 4S, pp. 4023–4031, 2024.
- [18] G. Zeng, "Invariance properties and evaluation metrics derived from the confusion matrix in

multiclass classification," Mathematics, vol. 13, 2609, 2025.

[19] G. Naidu et al., "A Review of Evaluation Metrics in Machine Learning Algorithms," Lecture Notes in Networks and Systems, vol. 724, pp. 15-25, 2023.

[20] Z. Wu, X. Zhu, dan D. Chen, "Adversarial Outlier Detection for High-Dimensional Data," IEEE Access, vol. 9, pp. 145696-145708, 2021.

[21] A. Bergman dan Y. Hoshen, "Classification-Based Anomaly Detection for General Data," International Conference on Learning Representations (ICLR), 2021.

[22] Z. Pang, Y. Xu, dan W. Wang, "Two-Stage Outlier Detection Based on Adaptive Feature Weighting," Knowledge-Based Systems, vol. 218, 106891, 2021.

[23] T. Ren, F. Fang, dan Z. Xu, "Hybrid Outlier Detection Using Cluster Density and Local Information," Expert Systems with Applications, vol. 168, 114254, 2021.

[24] R. Guo, P. Zhang, dan L. Li, "Anomaly Detection Enhancement Using Feature Projection and Isolation Mechanisms," Applied Intelligence, vol. 51, pp. 3020-3034, 2021.