

LOGBOOK PROJECT KELOMPOK

Mata Kuliah IF25-3025 / Penambangan Data

Informasi Project

Judul Project	Deteksi Anomali Menggunakan Isolation Forest, Local Outlier Factor (LOF) dan DBSCAN pada Studi Kasus Indeks Standar Pencemaran Udara (ISPU) DKI Jakarta 2010-2021
Tools	Python, Jupyter Notebook / Google Colab, scikit-learn, pandas, numpy, matplotlib, seaborn
Jenis Project	Unsupervised Anomaly Detection + Evaluasi Dampak terhadap Klasifikasi (Random Forest)

Anggota Kelompok

No	NIM	Nama	Tugas
1	123140043	Tengku Hafid Diraputra	Coding notebook dan pipeline integrasi
2	123140044	Jesika Filosovi Br P-A	EDA dan visualisasi data
3	123140062	Nabila Ramadhani Mujahidin	Preprocessing dan estimasi parameter
4	123140070	Annisa Salsabila	Implementasi LOF dan consensus voting
5	123140071	Willy Syifa Luthfia	Implementasi isolation forest
6	123140121	Fanisa Aulia Safitri	Implementasi DBSCAN dan evaluasi klasifikasi
7	123140188	Taufik Hidayat NST	Ketua kelompok, penulisan laporan dan dokumentasi

Logbook 10 Pertemuan

Minggu	Kegiatan	Output	Penanggung Jawab
1	Pembentukan kelompok, pemilihan	Topik dan dataset	Seluruh anggota

	topik, dan penentuan dataset. Diskusi awal terkait topik <i>anomaly detection</i> pada data kualitas udara ISPU DKI Jakarta.	disepakati	
2	Pengunduhan dataset ISPU DKI Jakarta dari Kaggle. Eksplorasi awal struktur dataset, identifikasi kolom, dan penentuan fitur yang akan digunakan (PM10, SO ₂ , CO, O ₃ , NO ₂).	Dataset tersedia dan dipahami strukturnya	Nabila Ramadhani M & Willy Syifa Luthfia
3	Studi literatur metode deteksi anomali (Isolation Forest, LOF, DBSCAN) dan consensus voting. Penyusunan alur penelitian (flowchart) dan pembagian tugas implementasi	Flowchart penelitian selesai, literatur terkumpul	Tengku Hafid Diraputra & Taufik Hidayat NST
4	Eksplorasi Data (EDA): analisis statistik deskriptif, distribusi kategori kualitas udara, distribusi fitur polutan per kelas, analisis <i>missing values</i> , dan visualisasi tren tahunan per stasiun.	Notebook EDA selesai beserta visualisasi (Gambar 1–4)	Jesika Filosovi Br P-A & Nabila Ramadhani M
5	Implementasi preprocessing: imputasi median per stasiun, <i>train-test split</i> stratified (80:20) sebelum scaling untuk menghindari <i>data leakage</i> , dan standardisasi menggunakan StandardScaler.	Pipeline preprocessing bebas <i>data leakage</i> selesai; training set 4.426, test set 1.107 sampel	Nabila Ramadhani M & Tengku Hafid Diraputra
6	Estimasi parameter: penentuan nilai <i>contamination</i> via aturan 3-sigma (diperoleh 0,0556) dan penentuan <i>eps</i> DBSCAN melalui <i>k-distance plot</i> pada ruang PCA 2 komponen (diperoleh <i>eps</i> = 7,621).	Parameter <i>contamination</i> = 0,0556 dan <i>eps</i> = 7,621 ditetapkan; <i>k-distance plot</i> (Gambar 3) selesai	Annisa Salsabila & Fanisa Aulia Safitri
7	Implementasi deteksi anomali: Isolation Forest (247 anomali, 5,58%), LOF (247 anomali, 5,58%), dan DBSCAN (0 anomali, 0%). Visualisasi sebaran anomali dalam ruang PCA 2D untuk ketiga metode.	Hasil deteksi ketiga metode selesai; visualisasi PCA 2D (Gambar 4–5) tersedia	Willy Syifa Luthfia, Annisa Salsabila & Fanisa Aulia Safitri
8	Implementasi consensus voting (threshold $\geq 2/3$ metode): diperoleh 98 anomali konsensus (2,21%). Visualisasi distribusi hasil voting dan scatter plot anomali konsensus dalam ruang PCA 2D.	98 anomali konsensus teridentifikasi; visualisasi voting (Gambar 6) selesai	Annisa Salsabila & Tengku Hafid Diraputra

9	Evaluasi dampak cleaning: pelatihan Random Forest pada kondisi <i>baseline</i> (4.426 sampel) dan <i>cleaned</i> (4.328 sampel). Perbandingan metrik Accuracy, Precision, Recall, F1-Score, dan AUC-ROC, serta pembuatan confusion matrix dan ROC curve.	Tabel perbandingan performa, confusion matrix, dan ROC curve (Gambar 7–8) selesai	Fanisa Aulia Safitri & Willy Syifa Luthfia
10	Penulisan laporan jurnal (Bab 1–5), penyusunan pembahasan, penyempurnaan narasi akademik, dan finalisasi notebook. Verifikasi pipeline <i>end-to-end</i> (Restart & Run All tanpa error).	Laporan jurnal final selesai; notebook terverifikasi tanpa error	Taufik Hidayat NST, Jesika Filosovi Br P-A & Tengku Hafid Diraputra

Output Project

- Notebook Python (.ipynb) pipeline deteksi anomali lengkap bebas *data leakage*, dapat dijalankan *Restart & Run All* tanpa error
- Laporan jurnal ilmiah lengkap dengan sitasi dan daftar pustaka
- Visualisasi hasil: distribusi kategori ISPU, analisis spasial & temporal, k-distance plot, PCA 2D scatter anomali, bar chart metrik, ROC curve, dan confusion matrix
- Tabel perbandingan performa klasifikasi *baseline* vs. *cleaned* (Accuracy, Precision, Recall, F1-Score, AUC-ROC)

Seluruh implementasi dilakukan menggunakan Python pada Google Colab. Pipeline menerapkan prinsip bebas *data leakage* —*train-test split* dilakukan sebelum seluruh proses preprocessing dan deteksi anomali. StandardScaler di-*fit* eksklusif pada *training set*.

Logbook Project Kelompok 3 - IF25-32025 Penambangan Data - Semester Genap
2025/2026